

公开葡萄病害数据集中的捷径学习：标注粒度是调制量而非成因

作者 [姓名]

单位 沈阳工学院 信息与控制工程学院，辽宁 抚顺 [请核对院系名称]

摘要

公开数据集是农业病害检测研究的主要数据来源，其可用性通常依据所报告的指标判断，而指标反映不出标注体系内部是否自洽。本文以一个公开葡萄病害检测数据集（3288 图，11995 框，6 类）为对象，考察公开数据的哪些固有属性决定检测系统的实际可用性。五组单变量对照覆盖模型容量 2.58 M 至 32 M、输入分辨率 384 至 960 以及一次检测范式更换，统一评估口径下测试集 mAP50 极差仅 1.54 个百分点，与随机种子波动同量级；分尺度评估在五个架构上一致地将瓶颈定位于小目标。主要发现在数据侧：mosaic virus disease 一类以整叶级标注为主（标注框中位面积占全图 43.16%），其余五类一致采用病斑级标注（0.57% 至 8.12%）。以 5156 张不含葡萄的跨物种图像作阴性对照，模型输出的 12221 个假阳性框中 65.7% 归入该类，相对训练占比过表达 13.41 倍，方向与类别频率先验相反。单变量反事实重训确立了粒度对该捷径**强度**的因果作用：仅缩小该类的标注框，其分布内 AP 由 0.7609 降至 0.4552，其余五类的变化均未超出种子间波动，跨物种假阳性同时减少 66%；安慰剂对照证实该效应特异于被操纵的类别。但一组事先注册判据的反向操纵给出阴性结果：把标注最细的一类粗化至整叶级（中位面积 0.57% → 40.37%），使其在粒度、标注框数与类别占比上与前述类别几近相同，其跨物种假阳性仍为 0 框（最高置信度 0.009，分布内 mAP50 为 0.990），而未被操纵的原类别仍占全部假阳性的 50.0%。据此本文将主张收窄为：**标注粒度决定该捷径的强度，不决定其归属**——粒度可放大或削弱一个已经存在的汇点，却不足以造就一个；决定归属的属性尚未确定。本文另提出一个无需图像与训练即可计算的粒度筛查量，并以同一口径区分出“一致地粗”与“类别间不齐”两种格局——危险的是后者；需注意该量度量的是标注体系自身是否自洽，而非假阳性的去向。此外，依成像光学关系核算，毫米级病斑的航拍检测在任何具备作业可行性的高度上均不可达。该失效模式在分布内评估中不可见，构成公开数据集可用性判断的一个盲区。

关键词：捷径学习；标注质量；目标检测；数据集可靠性；小目标检测

1 引言

1.1 背景

葡萄的主要真菌病害具有潜伏期：侵染在特定的温湿度窗口内完成，而肉眼可见的症状要在其后一至数周才出现。这使得防治的有效窗口与观察到症状的时刻并不重合。

本文作者持续观察了一处家庭种植的葡萄地块。该地块往年的处置方式是在幼果期施药一次，施药的时机与次数依据经验确定，无监测数据支持。尽管施药如期进行，果实仍在成熟前约一个月出现发病，症状为果面变黑。

本年度该地块未施药。7月下旬，果实（此时处于绿果期，未转色）表面出现针尖状黑色斑点；至8月初，同一果穗上多数果粒均带有此类斑点，部分果粒出现中央凹陷的圆形深色病斑，另有果粒呈现半果褐变与整果褐变；叶片上可见褐色坏死斑与叶缘干枯。病原尚未经实验室确认，故本文不作定性。

这一过程说明的问题是：**施药时机的判断依赖于症状的观察，而症状出现时，侵染已经完成。**早期、客观、可量化的病征观测因此成为改进防治时机的前提，也是本项目最初的出发点。

棚架或篱架栽培使叶幕在人的头顶展开，霜霉病的油渍状黄斑、白粉病的白色霉层主要出现在叶片正面，而人在架下只能看到叶背。低空俯视观察相对于人工地面观察的价值即在于此。

需要说明的是，本文全部实验使用地面近摄图像，无人机不构成本文的实验对象。飞行相关的结论仅出现在 5.1 节，且只依赖成像光学关系。

1.2 问题

本文围绕一个统领性问题展开：**公开数据集的哪些固有属性，决定了在其上训练的检测系统是否真正可用？**该问题分解为三个子问题，分别由本文的三个部分回答：现有方法在这份数据上能达到什么程度（第 3 节）；若达不到，制约来自模型容量、输入信息还是数据本身（3.2、3.3 节）；分布内的高指标能否作为实际可用的依据（第 4 节）。5.1 节讨论的采集可行性是同一问题在采集环节的延伸——数据在被标注之前，先要在光学上存在。

第三个子问题是本文的重点。它之所以要紧，是因为回答错了不会立刻暴露：模型照常输出，格式正常，置信度合理，而结论是错的。

1.3 本文工作

- 以统一评估口径完成五组单变量对照，确定该数据条件下的性能上限，
并以五种子重复给出组间比较所需的噪声基准；
- 分尺度评估在五个架构上复现，将瓶颈定位于小目标，
并指出该改善为聚合指标所掩盖；
- 量化类别之间标注粒度的不一致，设计跨物种阴性对照，
在 5156 张图像上验证由此诱发的捷径学习；
- 以四组单变量反事实重训分离标注粒度的作用：缩框组与安慰剂组确立其对捷径

强度的因果作用，一组事先注册判据的反向操纵（把最细的类别粗化至整叶级）给出阴性结果，据此将主张收窄为“粒度决定强度、不决定归属”；

- 提出一个无需图像与训练即可计算的粒度筛查量 R ，

并以同一口径在两个数据集上区分出“一致地粗”与“类别间不齐”两种格局；

- 核算病斑级航拍检测的光学可行性边界。

1.4 相关工作

捷径学习。 模型在训练分布内取得高分，却依赖与任务无关的表层线索，这一现象已被系统归纳为捷径学习^[1]。其典型表现是分布内指标正常而分布外急剧退化，且从聚合指标上无法察觉。医学影像领域的经典案例是模型依据胸片上的院内标记而非病灶作出判断^[2]；自然图像领域则有模型依赖场景上下文而非目标本身进行识别的报告^[3]。归因方法的研究亦表明，部分在基准上表现优异的模型实际依据的是图像中的无关区域^[4]。

已有工作与本文的差别在三处。其一，多数案例针对图像分类，目标检测中的捷径报道较少；检测任务中标注框的尺度本身构成一个可被利用的信号，这是分类任务所没有的通道。其二，多数研究将捷径归因于**图像内容**——背景、水印、拍摄设备痕迹——而本文定位到的诱因位于**标注体系**：图像本身无异常，每个标注框单独看也都正确，问题出在类别之间标注粒度的不一致。其三，多数工作止于现象描述与事后归因，本文以单变量反事实重训（4.4 节）确立了标注粒度对该捷径强度的因果作用，以安慰剂对照验证了效应的特异性，并以一组反向操纵划出该归因的边界——粒度不决定捷径的归属。

数据集标注质量。 主流基准数据集中存在可观数量的标签错误，且这些错误足以改变模型排序^[5]；对基准标注的重新审视也表明，原始标注协议本身会限制评估的有效性^[6]。本文关注的不是**标签错误**——本文所用数据集中的每个框都框住了真实的病征——而是**标签不一致**：同一数据集内，一类以整叶级标注为主，其余五类采用病斑级标注（2.1 节）。这类问题不会被标签纠错方法检出，因为不存在错误的标签，只存在不统一的粒度；它在分布内评估中同样不可见，甚至表现为该类的 AP 最高（表 7）。据我们所知，检测数据集内部标注粒度不一致所诱发的捷径，此前未见系统报告。

农业病害视觉识别。 该领域的公开数据以 PlantVillage 及其衍生数据集为主^[7]，在其上报告的分类准确率普遍很高^[8]。但后续工作指出，此类数据多在受控背景下采集，模型可仅凭背景信息完成分类，其高准确率并不反映田间条件下的能力^[9]。为缓解这一问题，田间条件下采集的数据集相继发布^[10]。

已有批评主要指向**采集条件**（受控背景、离体单叶、光照统一），本文指向的则是**标注体系**。二者是相互独立的缺陷维度：本文所用的葡萄病害数据集在采集条件上本身是混合的——既包含背景虚化的影棚式近摄，也包含手持病穗的田间实拍，另有由多张照片拼合而成的图像（2.1 节）——但无论采集条件如何，标注粒度的不一致贯穿其中。这意味着改善采集条件并不能消除本文所述的问题：若在重建数据集时沿用不统一的标注规范，同样的捷径会被带入新数据。

小目标检测与评估口径。 小尺寸目标的检测精度显著低于大目标，这一差距在多种架构上稳定存在^[11]；切图推理是常用的缓解手段之一^[12]。在评估侧，已有工作指出聚合指标会掩盖具体的失效模式，主张对检测误差按类型分解^[13]。本文 3.3 节给出的是同一问题在 **尺度维度**上的一个实例：提高输入分辨率使小目标 AP 显著提升（ $p = 0.018$ ），而聚合的 mAP50-95 无变化（ $p = 0.731$ ），仅依据后者会得出与事实相反的结论。5.1 节进一步指出，在航拍场景中该问题无法通过检测方法缓解——当目标在成像面上不足一个像素时，其信息在采集环节即已丢失。

2 数据与实验设置

2.1 数据集

主实验采用 Roboflow Universe 上发布的葡萄病害检测数据集 **grape**（工作区 **wscs**，项目标识 **grape-uyimv**，版本 1，发布日期 2025-11-03，许可 CC BY 4.0，地址 <https://universe.roboflow.com/wscs/grape-uyimv>），3288 张图像、11995 个标注框、6 个类别，按 2631 / 329 / 328 划分。图像经平台预处理为 640×640（EXIF 方向校正后拉伸缩放），未施加图像增广。标注对象为病斑级目标，单图平均 3.65 个框。该数据集由平台用户发布，未署名作者，按 CC BY 4.0 的要求，此处以上述地址作为出处标注。

表 1 类别分布

类别	标注框数	占比	主要症状形态
grape black rot	4237	35.3%	褐色圆斑，边界清晰
grape powdery mildew	2329	19.4%	白色粉状霉层，成片分布
grape downy mildew	1740	14.5%	叶面油渍状黄斑
grape botrytis cinerea	1553	12.9%	灰色霉层，侵染果穗枝干
grape ulcer disease	1543	12.9%	枝干组织褐变坏死
mosaic virus disease	593	4.9%	整叶花斑畸形

最多与最少类别之比为 7.1:1，属可接受范围，故全部类别参与训练，未做重采样。

统计各类标注框面积占全图的比例，可见一处明显差异：

表 2 各类标注框的面积占比

类别	中位	均值	P90
mosaic virus disease	43.16%	36.08%	64.85%
grape botrytis cinerea	8.12%	13.02%	29.47%
grape ulcer disease	3.29%	3.96%	6.19%
grape downy mildew	2.39%	4.74%	8.87%
grape powdery mildew	2.01%	2.95%	4.93%
grape black rot	0.57%	0.69%	1.21%

mosaic virus disease 的框中位面积为第二大类别的 5.3 倍、最小类别的 76 倍。

进一步考察该类的分布形态可以发现，其标注粒度在类内亦不统一：593 个标注框中，58% 的面积大于全图的 30%（对应整片叶片），28% 小于 10%（对应局部病斑），分位数为 $P_{10} = 5.3\%$ 、 $P_{25} = 8.9\%$ 、中位 43.2% 、 $P_{75} = 57.6\%$ ，呈双峰形态。作为对照，*grape botrytis cinerea* 仅 10% 的框大于 30%。

因此准确的表述是：该类以整叶级标注为主但混有病斑级标注，而其余五类一致采用病斑级标注。核查图像可确认这一判断。第 4 节的全部分析由此展开。




图 1 六类标注框相对面积的分布（对数横轴，虚线为 10% 与 30% 两条判定线）。五类病斑级标注的分布集中于 10% 以下；mosaic virus disease 单独位于另一量级，且呈明显双峰——右峰对应整叶级标注，左峰对应混入的病斑级标注。

数据集中另可观察到由多张照片拼合而成的图像。在一例中，同一张图内左上区域的叶片照被标注为 mosaic virus disease（占全图 15.4%），而右侧的果粒区域标注了 9 个 grape powdery mildew 的小框——**两种粒度出现在同一张图像内**，是标注规范不统一的直接体现。

此处需避免一种过度推广：本文的论断不是“标注框越大则 AP 越高”。grape botrytis cinerea 的框面积居第二位，其 AP 却是六类中最低的（表 7）。本文的论断仅针对 mosaic virus disease 一类所形成的具体捷径，以及 4.4 节安慰剂对照所显示的、粗标注类别共有的一项全局效应。

阴性对照与前期流程验证采用 FieldPlant 数据集^[10]（Roboflow Universe，工作区 plant-disease-detection，项目 fieldplant，版本 11，CC BY 4.0；5156 图，27 类，涵盖木薯、玉米、番茄），相关观察见 5.2 节，阴性对照的用法见 4.2 节。

2.2 实验设置

全部实验遵循单一变量原则：同一数据集与划分，训练轮次、等效批量、优化器策略、硬件环境一致。

项目	设置	说明
训练轮次	50	E5 实际训至第 16 轮中断，见 5.3 节
等效批量	8	E5 以 4×2 梯度累积实现；E4 为 4，未对齐
优化器	auto / AdamW	学习率由框架确定
混合精度	开启	YOLO 为 AMP，RF-DETR 为 bfloat16
显卡	RTX 4060 Laptop 8 GB	消费级笔记本显卡
框架	PyTorch 2.13.0+cu132	Ultralytics 8.4.106 ^[15] / RF-DETR 1.8.3 ^[16]
随机种子	0, deterministic	

E4（RT-DETR-1^[17]）的等效批量为 4，与其余组不一致，不构成严格单变量对照。本文仍如实报告该组——它以 32 M 参数、不同检测范式，结果与其余组打平，这一点支持本文关于模型侧优化空间的判断。

E5 的训练在第 16 轮中断，表现为数据加载速度无法匹配 GPU 的计算速度。当时未对瓶颈作进一步定位，无法区分其来自磁盘读取还是 CPU 端的预处理。该问题属于工程环境限制，与模型本身无关；5.3 节给出了所用权重具有代表性的验证。

2.3 评估口径

全部指标在测试集上报告，测试集在训练与调参全程未使用，验证集仅用于选取权重。该区分具有实际意义：E1 的验证集 mAP50 为 0.872，测试集为 0.8357，相差 3.6 个百分点。

指标一律由 pycocotools（COCO 官方评估实现^[14]）计算，置信度阈值 0.01。该口径必须统一——同一份 E1 权重，Ultralytics 内置评估器给出 0.845，pycocotools 给出 0.8357，差 0.9 个百分点，与本文所要讨论的组间差异是同一量级。混用两套口径的比较不成立。

3 性能上限与瓶颈

3.1 五组对照

表 3 测试集结果（统一 pycocotools 口径）

编号	模型	参数量	分辨率	批量	mAP50	mAP50-95
E1	YOLO11n	2.58 M	640	8	0.8357	0.5159
E2	YOLO11s	9.42 M	640	8	0.8493	0.5168
E3	YOLO11n	2.58 M	960	8	0.8459	0.5130
E4	RT-DETR-l	32 M	640	4	0.8427	0.5220
E5	RF-DETR-Nano	30.2 M	384	8	0.8511	0.5230

mAP50 极差 1.54 个百分点，mAP50-95 极差 1.00 个百分点。该区间覆盖参数量 12.4 倍、像素面积 6.25 倍的跨度，以及一次检测范式的更换。

该 1.54 个百分点的极差不足以支撑组间排序，依据有二。

其一为间接证据：E2 与 E3 在测试集上均高于 E1，在验证集上则均低于 E1，方向相反。

其二为直接证据：对 E1 的配置（YOLO11n@640）另换四个随机种子重复训练，其余设置逐项不变，连同 seed 0 共五次运行，在同一评估管线下得到：

表 4 同一配置的五种子重复（YOLO11n@640，n=5）

指标	均值	标准差
mAP50	0.8249	0.0069
mAP50-95	0.5076	0.0063
AP_small	0.1663	0.0080
AP_medium	0.3661	0.0245
AP_large	0.5865	0.0080

同一配置的 mAP50 标准差为 0.69 个百分点。表 3 中五组配置之间的极差 1.54 个百分点约合 2.2 个标准差——而从同一分布中抽五次，期望极差本就在 2.3 个标准差左右。观测到的组间差异完全可以由随机种子解释。

两点补充说明。

其一，表 3 各组报告的是 seed 0 的单次结果。就 E1 而言，seed 0 恰是五次中最高的一次（0.8357），比五种子均值高 1.08 个百分点——这一偏差量级与组间极差 1.54 个百分点相当。以单次运行作组间比较，在本数据规模下并不可靠。

其二，重复次数本身也需要足够。以 AP_medium 为例，前三个种子的结果为 0.3788 / 0.3820 / 0.3847，标准差仅 0.0030，看似极稳；补至五个种子后（加入 0.3263 与 0.3588）标准差升至 0.0245，为原先的 8 倍。n=3 时的方差估计会严重低估真实波动，据此判断显著性容易得出错误结论。

同一批权重的**逐类别** AP 波动另行统计，用作 4.4 节反事实比较的噪声参照，数值列于表 10 末列。各类别的相对标准差介于 1.0% 与 5.6% 之间，其中实例数最少的 grape botrytis cinerea（测试集 117 个实例）波动最大，五次运行的相对极差达 15.5%。**逐类别** 指标的种子间波动明显大于聚合指标，单次运行的逐类别比较须以此为噪声下界。

3.2 分尺度：瓶颈在小目标

表 5 五组实验的分尺度性能

编号	AP_small	AP_medium	AP_large	large/small
E1	0.1567	0.3788	0.5967	3.81×
E2	0.1642	0.4275	0.5847	3.56×
E3	0.1856	0.4520	0.5852	3.15×
E4	0.1927	0.4357	0.5969	3.10×
E5	0.1614	0.3282	0.5982	3.71×

大目标的 AP 为小目标的三至四倍，五个架构无一例外。这表明制约性能的并非模型对病害视觉特征的表达能力，而是目标的尺度本身；更换架构不能消除该差距。尺度分档依 COCO 的定义（small 为面积小于 32×32 像素）^[14]。

3.3 分辨率的效果为聚合指标所掩盖

E3 与 E1 的唯一差别是训练与推理分辨率（960 对 640）。依整体指标判断，该组毫无收益；但对两组各作五个种子的重复之后，分尺度的结果与整体指标给出的图景截然不同。

表 6 E1@640 与 E3@960 的分尺度比较（各五种子，Welch t 检验）

指标	E1 (n=5)	E3 (n=5)	差值	t	p
mAP50	0.8249 ± 0.0069	0.8370 ± 0.0096	+1.20 pp	2.28	0.055
mAP50-95	0.5076 ± 0.0063	0.5055 ± 0.0116	−0.21 pp	−0.36	0.731
AP_small	0.1663 ± 0.0080	0.1798 ± 0.0060	+1.35 pp	3.02	0.018
AP_medium	0.3661 ± 0.0245	0.4183 ± 0.0483	+5.22 pp	2.15	0.075
AP_large	0.5865 ± 0.0080	0.5809 ± 0.0103	−0.56 pp	−0.96	0.367

小目标 AP 的提升达到统计显著（p = 0.018），而整体 mAP50-95 完全没有变化（−0.21 个百分点，p = 0.731）。

关于多重比较需作说明。表 6 同时报告了五个指标，若一律按 $\alpha = 0.05$ 判断，存在多重比较问题。但 **AP_small** 是本文事前指定的主要终点：3.2 节已在五个架构上独立认定小目标为性能瓶颈，本节正是为检验“提高分辨率能否缓解该瓶颈”而设计，该假设在实验开展之前即已确立。其余四项为次要指标，仅作参考，本文不对其单独下结论。

关于重复次数亦需说明。3.1 节指出 n = 3 会低估方差，同一质疑原则上也适用于 n = 5。就本文所报的结论而言：AP_small 的标准差由 n=3 的 0.0094 变为 n=5 的 0.0080，相

对稳定；而 AP_medium 由 0.0030 变为 0.0245，变动剧烈。本文仅对前者下结论，对后者只报告趋势，正是基于这一差异。

这是本文关于评估方式的主要观察：聚合指标掩盖了瓶颈区间的真实改善。若仅以 mAP50-95 判断，会得出“提高分辨率无效”的结论，而实际上它恰恰改善了本文第 3.2 节所认定的瓶颈——小目标检测。

中目标的效应量更大（+5.22 个百分点，约为小目标的四倍），却未达显著（ $p = 0.075$ ），原因是该指标的种子间波动本身很大（E1 的标准差 0.0245，E3 为 0.0483，分别是小目标标准差的 3 倍与 8 倍）。AP_medium 在本数据上是一个不稳定的指标，这一点在设计后续实验时需要注意——它需要更多重复才能支撑同等强度的结论。

3.4 召回率的尺度依赖

E5 的平均召回率随允许输出的框数呈阶梯上升：maxDets 为 1 时 0.2676，10 时 0.5874，100 时 0.6729，尚未饱和。RF-DETR 使用固定数量的学习式查询（本实验为 300 个），图像内目标数超过查询数时输出将被截断。真实场景下单片叶片可能带有数十个病斑，该限制在部署时需予以考虑。

3.5 类别层面分析

表 7 各类 AP50-95

类别	测试集实例	E1	E2	E3	E4	E5
grape black rot	446	0.5668	0.5742	0.5620	0.5764	0.5649
grape botrytis cinerea	117	0.3454	0.3403	0.3167	0.3839	0.3801
grape downy mildew	170	0.4962	0.4925	0.5077	0.4579	0.4962
grape powdery mildew	313	0.3711	0.3816	0.3870	0.3892	0.4005
grape ulcer disease	133	0.5549	0.5689	0.5511	0.5609	0.5061
mosaic virus disease	63	0.7609	0.7435	0.7537	0.7636	0.7903

在置信度 0.25、IoU 0.5 这一常用工作点上统计混淆矩阵，结果与预期不符：类间混淆几乎不存在（非对角元素合计仅 4 个），错误几乎全部来自漏检与背景误报。

表 8 E1 的检出情况（ $\text{conf} \geq 0.25$ ， $\text{IoU} \geq 0.5$ ）

类别	实例数	正确检出	误判为他类	漏检	背景误报	召回率
grape black rot	446	420	0	26	36	94%
grape botrytis cinerea	117	83	0	34	57	71%
grape downy mildew	170	144	0	26	54	85%
grape powdery mildew	313	241	0	72	157	77%
grape ulcer disease	133	113	4	16	39	85%
mosaic virus disease	63	58	0	5	16	92%
合计	1242	1059	4	179	359	85%

全部 1242 个真值实例中，被判为其它类别的仅 4 个（grape ulcer disease 3 个判为 grape botrytis cinerea、1 个判为 grape powdery mildew），占 0.32%；而漏检 179 个、背景误报 359 个。

grape botrytis cinerea 的 AP 最低（0.3454），其原因并非与 grape ulcer disease 难以区分——二者之间的误判仅 3 例——而是召回率只有 71%，近三成实例未被检出，同时伴有 57 个背景误报。grape powdery mildew 的背景误报最多（157 个），其 AP 亦偏低（0.3711）。

本数据上的主要误差来源是定位而非分类。模型的失败发生在“能否找到目标”这一环节，而非“找到之后判为哪一类”。这与 3.2 节的分尺度结论一致：瓶颈在于小尺寸目标的检出，而非病害类别的可分性。

需要说明，本文早先曾依据 Ultralytics 输出的归一化混淆矩阵图，判断 grape botrytis cinerea 与 grape ulcer disease 存在严重互混。以原始计数复核后该判断不成立，此处予以更正。

此处出现一项反常：mosaic virus disease 的测试集实例最少（63 个），其 AP 却在五个架构上均列第一。样本量最少的类别取得最高得分，与通常的规律相悖；结合表 2 所示的标注面积差异，两项线索指向同一处。

4 捷径学习

4.1 假设

两项观测指向同一个类别：其标注框比其余类别大一个数量级（表 2）；其样本量最少而 AP 最高（表 7）。

由此提出假设：模型在该类上的高分并非源于对花叶病毒症状的识别，而是标注粒度的差异提供了一条可被利用的捷径。

4.2 跨物种阴性对照

检验该假设需要一批可确定不含葡萄花叶病毒的图像。自采的 10 张手机照片不能胜任：样本量过小，且“某片叶片是否感染花叶病毒”只能依靠肉眼判断，缺乏客观真值。

改用 FieldPlant 的 5156 张图像。其拍摄对象为木薯、玉米与番茄，不可能含有葡萄花叶病毒，因此模型在其上输出的任何葡萄病害均为假阳性，真值客观且无需人工判定。评估使用 E1 权重，置信度阈值 0.25。

表 9 假阳性的类别分布（全分辨率解码）

类别	训练框面积	训练占比	预测占比	过表达
mosaic virus disease	43.16%	4.9%	65.7%	13.41×
grape botrytis cinerea	8.12%	12.9%	31.3%	2.42×
grape downy mildew	2.39%	14.5%	2.4%	0.16×

grape black rot	0.57%	35.3%	0.5%	0.02×
grape powdery mildew	2.01%	19.4%	0.0%	0.00×
grape ulcer disease	3.29%	12.9%	0.0%	0.00×

5156 张里有 3697 张 (71.7%) 产生了输出，共 12221 个假阳性框。其中 1408 张 (27.3%) 以超过 0.5 的置信度被判为葡萄花叶病毒，744 张超过 0.7，最高一张 0.948。




图 2 各类别在训练集中的标注框占比（空心）与在跨物种阴性图像上的假阳性占比（实心），按训练框中位面积自上而下递减排列。除 mosaic virus disease 外，所有类别的假阳性占比均低于其训练占比；唯独标注最粗、训练占比最低的该类反向大幅升高，由 4.9% 升至 65.7%。

一项必要的排除。 过表达最严重的恰好是训练集中最稀有的类别（4.9%）。类别频率先验只会使高频类被过度预测，方向与观测相反（Spearman 相关系数 -0.638）。该偏置因此不能归因于类别不平衡。

两项混淆因素的辨析。 需要区分“为何会出现假阳性”与“假阳性为何集中于某一类”，二者是不同的量，本文的论断只涉及后者。

其一，训练集几乎不含无病征的纯健康图像，模型未曾见过“无病征”这一状态。这足以解释假阳性的总体水平（71.7% 的图像产生了输出），但不能解释其类别分布——健康负样本的缺失对六个类别没有方向性，无法说明为何 65.7% 的假阳性集中于训练占比最低的那一类。更关键的是，该因素在 4.4 节的三组反事实中保持恒定：三组使用同一批训练图像，同样不含健康样本，组间唯一的差别是标注框的尺寸。因此它影响假阳性的水平，不影响组间的差分，而本文的因果论断建立在后者之上。健康负样本的独立效应需另设实验测定，列为后续工作（第 6 节）。

其二，FieldPlant 与主数据集除作物种类外，采集条件亦不相同，假阳性总量中包含域偏移的贡献。该因素同样只作用于水平而不作用于类别分布，且 4.4 节的三组反事实在同一批阴性图像上比较，域偏移对三组是共同的。

4.3 一个未获支持的解释

我们原先将该现象归因于一条具体规则：画面中存在占大面积的、叶片形状的绿色区域时，模型即判为花叶病毒。该规则表面合理，但经检验不成立。

对每张图计算最大绿色连通区域占比，与该类预测的出现率对照：

最大绿色区域占比	图像数	出现该类预测的比例
0.00 - 0.05	31	6.5%
0.05 - 0.15	171	14.6%
0.15 - 0.30	678	40.7%
0.30 - 0.50	1222	52.6%
0.50 - 0.70	1230	51.7%
0.70 - 1.01	1824	30.4%

分组比例呈倒 U 形，但整体相关系数仅 -0.092 ，实质为零；无输出图像与有输出图像的绿色区域占比中位数分别为 0.570 与 0.586 ，二者不可区分。此外，该类预测框的面积中位数仅 3.8% ，并未复现训练标注中的 43.2% 。

该解释应予撤回。现象本身是稳固的，但模型所依据的具体图像特征尚不清楚。

4.4 反事实重训

图像层面的触发特征既未能定位，转而直接在数据一端操纵变量。

构造两份反事实数据集，训练超参与 E1 逐项一致：

shrink 组保留该类及其全部样本，仅将每个标注框裁至中心 25% 面积，中位面积占比由 43.16% 降至 10.79% ，与 *grape botrytis cinerea* 同量级。图像、框数、类别数与类别身份均不变，唯一改变的是标注粒度。

该操作成立的前提是：花叶病毒的症状为全叶弥漫性花斑而非局部病斑，裁至中心后框内仍为真实的症状组织。对黑腐病一类的局部圆斑则不成立，故该操作只施加于本类。

需要说明的是，该类中约 28% 的标注框原本即为病斑级（面积小于 10% ，见 2.1 节），对这部分框施加同样的裁剪会使其进一步缩小。我们未对两部分作区别处理，以保持操作的单一性。这一处理对两类指标的影响方向不同，需分别说明：

就**跨物种假阳性**而言，真正实现“整叶级→病斑级”转换的仅占该类的 58% ，其余部分的裁剪与本节假设无关，相当于稀释了处理强度，因此所测得的 -66% 是对该效应的**保守估计**。

就**分布内 AP**而言，对原本已经很小的框继续裁剪会额外增加检测难度，可能使 AP 的下降幅度被高估。这一点与下文所述的主要效度威胁同源，应合并考虑。

drop 组直接剔除该类。该组的训练图像由 2631 降至 2354 （减少 10.5% ，因部分图像仅含该类标注），存在样本量的混淆，故只作旁证。

判据在实验开展之前即已确定：shrink 组在 FieldPlant 上的过表达若显著回落， 则标注粒度对该捷径具有因果作用。

本节的跨物种测试统一采用 1/4 分辨率解码。FieldPlant 为约 1300 万像素的原图， 全分辨率解码的耗时为 1/4 分辨率的 3.4 倍，而图像最终均需缩放至 640 输入模型。基线 E1 在该设置下重新测定，过表达为 $11.95\times$ （全分辨率下为 $13.41\times$ ）。三组设置一致，组内可比。

结果一：分布内的异常高分随粒度归一化而消失

两组各在其自身的标注体系下评估——shrink 组的测试集标注同步缩小——指标由 pycocotools 计算，与表 3、表 7 同口径。末列为同一配置五个随机种子的逐类别 AP 相对极差（3.1 节），作为噪声参照。

表 10 缩框前后的分布内逐类 AP50-95（统一 pycocotools 口径）

类别	E1 原标注	shrink 组	变化	种子间相对极差 (n=5)
mosaic virus disease	0.7609	0.4552	-40.2%	3.2%
grape black rot	0.5668	0.5600	-1.2%	2.5%
grape botrytis cinerea	0.3454	0.3184	-7.8%	15.5%
grape downy mildew	0.4962	0.4785	-3.6%	8.2%
grape powdery mildew	0.3711	0.3809	+2.7%	5.8%
grape ulcer disease	0.5549	0.5503	-0.8%	2.1%

未被操纵的五类，其测试集标注在两份数据中逐字相同，实测 AP 的变化均小于该类自身的种子间波动，即在本文的分辨能力下不可区分；被操纵的类别下降 40.2%，为其种子间相对极差（3.2%）的 12.6 倍。该类由遥遥领先的第一（0.7609，第二名 0.5668）落至六类中的第四（0.4552）。表 7 中“样本最少却得分最高”的反常，随标注粒度的归一化而消失。

需说明评估方式的选择。以 E1 权重直接在缩框后的测试标注上评估，该类 AP 为 0：框面积缩至原来的 25%，同心框的 IoU 上界即为 0.25，两套标注体系在 $\text{IoU} \geq 0.5$ 下几乎不重叠。因此只能令各组在各自的标注体系下评估， 比较的是“该类相对其余五类的位次”，而非跨标注体系的绝对数值。

结果二：跨物种假阳性大幅下降

表 11 反事实重训在 FieldPlant 上的假阳性（1/4 分辨率解码）

组别	该类假阳性框	过表达	假阳性总数
E1 原标注（框 43.2%）	5379	$11.95\times$	9176
shrink 组（10.8%）	1805（-66%）	$6.16\times$ （-48%）	5971
drop 组	0	—	7056

结果三：剔除该类未能消除问题

表 12 剔除目标类后假阳性的转移（1/4 分辨率解码）

类别	训练框中位面积	E1	drop 组
grape botrytis cinerea	8.12%	3537	5350 (+51%)
grape downy mildew	2.39%	215	1225 (+469%)

假阳性转移至标注次粗的类别。这表明捷径并不依附于 mosaic virus disease 这一特定病害：移除该类之后，分布外输入改由其余类别承接。这同时解释了 shrink 组（假阳性总数 5971）何以优于 drop 组（7056）：前者改变了产生捷径的条件，后者仅移除了承接该捷径的类别。

承接者恰为标注次粗的两类，提示“标注最粗的那一类即分布外输入的归属地”。该推论看似自然，但由本组数据无法确立——botrytis 与 downy mildew 本就是 E1 中假阳性数量排名第二与第三的类别（3537 与 215，表 9），其承接顺位在操纵之前即已存在，与粒度排序混淆。要确立该推论，需要一项独立的反方向检验：把一个原本不承接的细粒度类别粗化，看它是否因此成为归属地。结果五给出的答案是否定的。

两点保留

其一，标注粒度并非全部成因。缩框之后仍存在 6.16 倍的过表达，粒度约解释其中一半，其余部分的成因尚不清楚。

其二，最主要的效度威胁在于：缩小标注框本身即提高了检测难度，AP 的下降不必然指示捷径的存在。对此有两点回应。一方面，任务难度的提高无法解释跨物种假阳性减少 66%，后者与标注框的尺寸无直接关系，两项结果需合并解释方能成立。另一方面，归一化之后该类的 AP 为 0.4552，与框面积同量级的 grape downy mildew (0.4785)、grape botrytis cinerea (0.3184) 处于同一区间——该尺度的目标并非不可检测，下降的是该类相对其余类别的**异常优势**，而非其绝对可检测性。

结果四：效应特异于被操纵的类别

为排除“任何标注扰动均会降低假阳性”这一泛泛解释，另设第三组对照：保持 mosaic 不变，改缩 grape botrytis cinerea（训练框面积居第二，8.12%）的标注框，同样缩至 25% 面积（降至 2.03%），其余条件不变。

表 13 三组反事实的每图假阳性对比（1/4 分辨率解码）

组别	mosaic	botrytis	假阳性总数
E1 原标注	1.043	0.686	9176
缩 mosaic 框	0.350 (−66%)	0.710 (+4%)	5971
缩 botrytis 框	0.579 (−44%)	0.108 (−84%)	3956




图 3 三组反事实跨物种阴性图像上的每图假阳性框数（1/4 分辨率解码），百分比为相对 E1 原标注的变化，各组下方标注假阳性总数。中间一组显示效应的特异性（被操纵的 mosaic 下降 66%，未被操纵的 botrytis 不变）；右侧一组显示两种机制的方向差异——缩 botrytis 使其自身下降 84% 的同时，未被操纵的 mosaic 亦下降 44%，与“归属机制”单独作用时应有的上升相反。

效应集中于被操纵的类别：缩 mosaic 使其假阳性下降 66%，而 botrytis 几乎不变（+4%）；缩 botrytis 则使其自身下降 84%。这排除了“扰动标注即可降低假阳性”的解释。

结果五：粗化一个细粒度类别未能造出新的归属地

前三组操纵一律是“由粗改细”，因而只能表明削弱粒度会削弱捷径，无法表明粒度足以造就捷径。若归属地确由标注最粗的位置决定，则反方向的操纵应当同样有效：把一个细粒度类别粗化至整叶级，它应成为分布外输入新的归属地。本组直接检验这一推论。

选定 grape black rot。该类标注框中位面积占比 0.57%，为六类中最细，且在 E1 的跨物种假阳性中仅占 0.41%（38/9176），从来不是归属地。该类为局部褐色圆斑的真菌病害，不存在“系统侵染故应标注整叶”的生物学理由，因而该组同时检验一项独立的质疑：捷径究竟取决于标注粒度，还是取决于病害本身的症状形态。若粗化后该类同样成为归属地，则前者成立。

操作不含任何可调系数：取同一张图内该类全部病斑框的外接框，以单个框替代之。这正是标注员在整叶级口径下会画的那个框。该操作使该类在多项结构属性上同时与 mosaic virus disease 相当。

表 14 粗化后的 grape black rot 与 mosaic virus disease 的结构对照

	grape black rot（粗化后）	mosaic virus disease
--	----------------------	----------------------

标注框数	476	593
占全部标注	5.8%	4.9%
每图标注框数（中位）	1	1
中位面积占比	40.37%	43.16%
分布内 AP50-95	0.8547	0.7338
跨物种假阳性框	0 (0.0%)	3718 (50.0%)

判据于训练完成之前写定，且以**原始预测占比**而非过表达倍数为主指标：粗化必然使标注框数下降（整叶级标注本就一叶一框），该类由 4237 框降至 476 框，训练占比由 35.3% 降至 5.8%，分母缩小 6.1 倍会机械地抬高过表达倍数。判据分三档——该类预测占比升至 10% 以上且原类别显著下降，则归属随粒度转移；落在 2% 至 10%，则粒度只造成部分倾向；低于 2% 且原类别不变，则该推论不成立。

实测落在第三档：该类在 5156 张跨物种图像上输出 **0 个框**。这不是置信度阈值造成的假象。将阈值由 0.25 降至 0.001 复测（每 6 张抽 1 张，共 860 张），该类在 E1 下有 207 个框、最高置信度 0.630，在本组下仅 33 个框、最高置信度 0.009。同一模型对该类的分布内 mAP50 为 0.990，为六类中最高——模型对该类的检测能力完好，只是从不把陌生输入判入其中。

标注框数的下降不足以解释这一结果。 该类的标注框虽减少了 89%，但 mosaic virus disease 本身即是一个仅有 593 框、占全部标注 4.9% 的类别，与粗化后的 grape black rot（476 框，5.8%）几乎相同，却承接了全部假阳性的一半。在本数据集上，“粗且稀少”的两个类别，一个是最大的归属地，另一个完全不承接。

一项附带观测：未被操纵的 mosaic 亦随之下降。 本组只改动了 grape black rot 的标注，但 mosaic virus disease 的跨物种假阳性由 5379 框降至 3718 框（-31%），而其余四类合计由 3759 框降至 3714 框（-1.2%），几乎未动。

这不是标注总量下降造成的整体缩放。粗化使全数据集的标注框由 11995 降至 8234（-31%），若模型的输出倾向因此整体下调，其余四类应同样下降，实测却仅为 -1.2%：下降特异地发生在 mosaic 一类。该形态与安慰剂组同向——操纵 mosaic 之外的某一类别，均使未被操纵的 mosaic 下降（安慰剂组 -44%，本组 -31%），且两组的被操纵对象不同，构成两次独立观测。二者的形态并不完全一致（安慰剂组的假阳性总量降至三组最低的 3956，本组其余四类则纹丝不动），共有的是跨类别的效应，其机制未获进一步阐明。

结论：粒度决定强度，不决定归属

四组反事实——缩框、剔除、安慰剂、反向操纵——须合起来读。缩框组与安慰剂组表明，改变一个类别的标注粒度会同时改变该类自身的分布外假阳性（-66%、-84%）与假阳性总量（9176 → 5971 → 3956），其中跨类别的效应有两次独立观测：缩小 botrytis 的标注框使**未被操纵的 mosaic 下降 44%**，粗化 black rot 使其下降 31%（而其余四类仅动 -1.2%）——削弱或改动任一其他类别所降低的，不只是该类自身的承接量。就此而言，标注粒度对捷径的**强度**具有因果作用，且其收益不限于被修正的那一类，因此不宜只修最粗的一类，而应对全部粗标注类别一并处理。

反向操纵组则表明，加粗标注并不能使一个类别成为分布外输入的归属地：在粒度、标注框数与类别占比均与 mosaic virus disease 相当、而分布内性能犹有过之（AP50-95 0.8547 对 0.7338）的条件下，grape black rot 的跨物种假阳性为 0。

因此 4.1 节的假设应收窄为：**标注粒度是该捷径的调制量，而非其成因。**它可以放大或削弱一个已经存在的归属地，却不足以造就一个。drop 组中假阳性向次粗类别的转移，相应地应读作“在既有的承接倾向之间重新分配”，而非“粒度赋予了承接资格”。

决定归属的属性本文未能确定。粗化后的 grape black rot 与 mosaic virus disease 之间，所有已测量的标注属性均已对齐，二者的差别只可能来自两类图像本身的内容。一个未经检验的候选解释是：分布外输入被判入的，是训练图像在整体外观上与之最接近的类别，而非标注框最大的类别。检验该解释需要图像层面的分布距离度量，本文未作，列为后续工作（5.3 节）。该组同时说明，4.3 节撤回绿色区域假设之后所留下的空缺——模型究竟依据什么把陌生输入判给某一类——并未由标注粒度填补。

4.5 该失效模式的特殊危险性

该失效模式的表现不是“未能检出”，而是“稳定地输出同一个错误答案”，其危险性有三。

置信度高，阈值调节无效。将阈值由 0.25 提高至 0.5，误判并不消失：5156 张阴性图像中仍有 1408 张以 0.5 以上的置信度被判为花叶病毒，744 张超过 0.7。提高阈值只会同时损失真阳性。

在常规监控中不可见。输出格式正常，置信度分布合理，不作逐样本的可视化核查即无法察觉。

其代价高于无输出。系统若投入使用，使用者将依据错误结论施药，其代价高于系统明确报告“无法判断”。

5 讨论

5.1 病斑级航拍检测的可行性边界

我们最初的推理是：小目标 AP 仅 0.16，故需降低地面采样距离，因而需要两级航线。该推理存在一处缺陷——0.16 测自地面近摄图像，其是否可外推至航拍视角未经验证。

改由成像光学关系直接核算，不依赖任何跨域假设：

$$GSD = \text{像元尺寸} \times \text{飞行高度} / \text{焦距}$$

COCO 的尺寸分档在图像上定义，与采集方式无关（small 为面积小于 32×32 像素）^[14]。

表 15 各机型在 30 m 高度的分辨能力

相机	GSD	达 32 像素所需的目标尺寸
1/1.3" 48 MP, f=6.7 mm	5.33 mm/px	17.1 cm

4/3 20 MP, f=12.29 mm	8.00 mm/px	25.6 cm
1" 20 MP, f=8.8 mm	8.22 mm/px	26.3 cm
1/1.3" 12 MP 长焦, f=43 mm	1.66 mm/px	5.3 cm

表 16 使 5 mm 病斑达到给定像素尺寸所需的高度上限（1/1.3" 48 MP）

要求	高度上限	单帧覆盖	覆盖 1 公顷所需张数
达 32 px（脱离 small）	0.88 m	1.26 × 0.94 m	约 14 万
达 96 px（进入 large）	0.29 m	0.42 × 0.31 m	—

张数按摄影测量常规的航向 80%、旁向 70% 重叠计算。即便按无重叠的理想情形，覆盖一公顷仍需约 8400 张，结论不受该假设影响。

30 m 高度下，5 mm 病斑只占 0.94 个像素。

结论是明确的：毫米级病斑的航拍检测，在任何具备作业可行性的高度上均无法实现。这属于光学限制而非模型能力问题——当目标在成像面上不足一个像素时，信息在采集环节即已丢失，任何小目标检测方法都无从施力。长焦镜头可将最小可分辨尺寸压至 5.3 cm，是其中最有效的手段，但与毫米级仍相差一个数量级。

因此所需的并非两级航线，而是两级系统：航拍一级（30 - 50 m）承担冠层与整株尺度的异常定位——变色区域、长势异常、缺株，这些目标在 17 cm 以上，光学上可分辨；病斑级的确诊由地面近摄承担。本文所用的数据集与模型对应的正是后一级。

需强调，上述高度仅为必要条件。该高度下实际可达到的检测精度必须以真实航拍数据测定，而本文全部实验使用的是地面近摄图像。

5.2 数据建设

先给出一个可在使用数据之前施加的筛查量。第 4 节的现象源于标注粒度在类别之间的不一致，而这种不一致可以在不读取任何图像、不训练任何模型的前提下直接算出：以类内标注框相对面积的中位数 m_c 刻画每一类的粒度（YOLO 归一化标注下相对面积即 $w \times h$ ），再以

$$R = \max_c(m_c) / \text{median}_c(m_c)$$

刻画最粗的类别偏离典型类别的程度。分母取类间中位数而非最小值，以免被单个极细的类别放大。判定阈值先验设定为： $m_c \geq 30\%$ 记为整叶级（占全图三成以上的标注框不可能框住单个病斑）， $m_c \leq 10\%$ 记为病斑级，中间地带不作判定。

R 刻画的是“有多不齐”，但不足以刻画“最粗的那一类是否孤立”。后者由最粗类与次粗类的中位数之比 $m_{(1)}/m_{(2)}$ 给出，两项须并列考察：一个数据集可以整体偏粗而队首并无断层，也可以整体偏细却存在一个孤立的最粗类别。两者刻画的都是标

注体系的自治程度，而非模型行为；下文将说明， $m_{(1)}/m_{(2)}$ 接近 1 并不足以断定该数据集中不存在捷径的归属地。

表 17 两个数据集的标注粒度分布（同一口径）

数据集	类别数	标注框数	类间中位 m	最粗类 m	$m_{(1)}/m_{(2)}$	整叶级 / 病斑级类数	粒度跨度 R
本文主数据集（葡萄）	6	11995	2.84%	43.16%	5.32×	1 / 5	15.2×
FieldPlant（木薯 / 玉米 / 番茄）	27	8580	33.49%	87.46%	1.06×	17 / 1	2.6×

两项指标对小样本类别的敏感程度不同。将参与统计的类别限定为标注框数不少于 10、30、100 个时，主数据集的两项均恒为 15.2× 与 5.32×（其六个类别的标注框数最少也有 593 个，不受阈值影响）；FieldPlant 的 R 稳定在 2.4× 至 2.7×，而 $m_{(1)}/m_{(2)}$ 由 1.06× 升至 1.89×——因为剔除小样本类别会改变排在首位的类别。即便取该区间的上端，仍远低于主数据集的 5.32×。

两个数据集分属不同的格局，“粗”与“不一致”是两件事。FieldPlant 的标注整体处于整叶级——27 类中 17 类的中位面积超过 30%，类间中位数本身即为 33.49%——但各类彼此接近：最粗的类别仅比次粗者高出 6%（1.06×），队首没有断层。本文主数据集则相反：五类为病斑级（中位 0.57% 至 8.12%），唯独一类为整叶级（43.16%），高出类间中位数 15.2 倍、次粗类别 5.3 倍（2.1 节）。

这一对照与第 4 节的机制有关，但其关系需谨慎表述。4.4 节的反向操纵组（结果五）恰好是一次人为把 $m_{(1)}/m_{(2)}$ 由 5.32× 压到 1.07× 的构造：粗化之后，主数据集出现两个并列的整叶级类别（43.16% 与 40.37%），按上述筛查量已属“队首无断层”的格局，即 FieldPlant 那一型。若归属地确由最粗的位置决定，假阳性理应在两类之间分裂；实测并未分裂——50.0% 仍集中于原类别，新粗化的类别为 0。**因此 $m_{(1)}/m_{(2)}$ 接近 1 并不意味着该数据集中不存在归属地。*

这一阴性结果限定了两项筛查量的适用范围，但并未取消其价值。 R 与 $m_{(1)}/m_{(2)}$ 度量的是标注体系自身是否自治；类别间粒度不齐是一个可在训练之前发现、且已被证明会放大分布外假阳性的缺陷（4.4 节结果一至结果四）。它们不能被当作“该数据集是否存在捷径归属地”的预测量。因此本文的主张表述为：**危险的不是标注粗，而是类别之间粒度不齐；但粒度齐整并不保证不存在捷径。**

其实践含义是一条可执行的筛查：使用公开检测数据集之前先算一次 R ，代价仅为遍历标注文件（秒级，无需图像与 GPU）。 R 越大，越应在训练之前核查最粗的那一类，或统一其标注粒度。

以下各条均由前文结果直接导出。

标注粒度必须在类别之间统一。 第 4 节表明，混用整叶级与病斑级标注，可使模型在分布内评估中于该类取得最高分（0.74 至 0.79），同时在分布外产生 13.41 倍的过表达假阳性；仅依据分布内指标无法察觉该问题。4.4 节的安慰剂对照进一步显示，该项要求不限于粒度最粗的类别：缩小任一粗标注类别的标注框，都会同时降低假阳性总量，故应对全部粗标注类别一并规范，而非只处理最突出的一类。

训练集应纳入足量的健康（无病征）样本。 本文所用公开数据集几乎不含纯健康图像，模型未曾见过“无病征”这一状态，这可能是 4.2 节中 71.7% 的图像均产生输出的原因之一。需说明该条与前一条处于不同层次：健康样本的缺失影响的是模型在陌生输入上**是否产生输出**，标注粒度影响的是既有假阳性的**强度**（4.4 节）。粒度不决定假阳性的类别归属——该推论已由 4.4 节的反向操纵组否定。两项因素的定性辨析见 4.2 节，前者的独立效应本文未作测定，列为后续工作。

自采数据宜参与训练，而非仅用作测试。 需要说明，该条系基于前述各条的推论与既有文献的建议，**本文未对其提供直接实验证据**——4.2 节因样本量不足（10 张）已将自采数据排除在正式实验之外。此处列出是为后续数据建设提供参考，其验证有待自采数据集完成标注后另行开展。

公开数据集须经人工抽样可视化核查，不能仅依据指标判断。 抽检可发现的不止于错标。在本文主数据集中，仅通过逐张查看图像即可发现由多张照片拼合而成的样本，其中同一张图内左上区域的叶片被标注为 mosaic virus disease，右侧果粒区域则标注了 9 个 grape powdery mildew 的小框——**两种标注粒度出现于同一张图像之内**（2.1 节）。这类问题不会在任何指标上显现，却正是第 4 节所述捷径的来源。

前期以 FieldPlant 作流程验证时，抽检标注图亦发现玉米叶被标为番茄类别——玉米为单子叶、平行叶脉，与番茄的羽状复叶差异明显，属明确的标注错误；另有严重的标注不全，一张图中清晰可见十余片叶片而实际仅标注 1 至 4 片，致使模型检出真实存在但未被标注的目标时被计为误报。上述问题均无法由指标发现。

5.3 局限

捷径的归属由什么决定，本文未能回答。 这是本文最主要的未决问题。4.4 节的反向操纵组表明标注粒度不是答案：把最细的类别粗化至与 mosaic virus disease 在粒度、标注框数与类别占比上均相当、分布内性能犹有过之（AP50-95 0.8547 对 0.7338），其跨物种假阳性仍为 0。4.3 节所检验的绿色区域假设亦已否定。因此“模型依据什么把陌生输入判给某一类”这一问题，在本文结束时仍然开放。

一个未经检验的候选解释是：归属地由训练图像与分布外输入在**整体外观**上的接近程度决定，而非由标注框的尺寸决定。该解释可以被检验——例如以特征空间距离或图像统计量度量各类训练图像与 FieldPlant 图像的分布距离，再考察该距离能否预测各类的假阳性承接量。本文未作此项测定，原因是它需要一套与本文其余部分不同的度量方法，且其结论会依赖所选特征提取器，须另行设计对照方能成立。若该解释获得支持，则第 4 节的现象应重新表述为

一个域相似性问题，而标注粒度退居为强度上的调制因素——这与本文现有结论相容，但归因的层次会发生变化。

全部实验使用地面近摄图像，向航拍视角的迁移未经检验。 本文不对无人机场景下的检测性能作任何断言，5.1 节的结论只依赖光学关系。

重复次数仍然有限。 E1 与 E3 各做了五个种子，E2、E4、E5 仍是单次运行。表 3 的组间比较因此只能表明“差异与种子波动同量级”，不能进一步区分。若要对具体某两组下结论，需按 3.1 节的方式各做重复。3.3 节 AP_small 的显著性判断 ($p = 0.018$) 同样建立在 $n = 5$ 之上，虽然该指标的方差估计在 $n=3$ 至 $n=5$ 之间相对稳定（标准差 $0.0094 \rightarrow 0.0080$ ），但更大规模的重复仍有必要。

反事实各组亦为单次运行。 三组反事实（shrink、drop、安慰剂）均以 seed 0 训练一次。为使单次比较可解释，本文以同一配置五个种子的逐类别 AP 波动作为噪声参照（表 10 末列）：被操纵类别的变化达其种子间相对极差的 12.6 倍，远超噪声；而未被操纵的五类，其变化均落在各自的噪声范围之内，因此只能判定为“在本文分辨能力下无可检出的变化”，不能判定为严格的零效应。

E5 的训练轮次与其余组不一致。 该组因数据加载速度受限中断于第 16 轮，采用第 13 轮的最优权重。为确认该权重是否具有代表性，我们自中断处继续训练至第 29 轮：验证 mAP50 在其后 16 个 epoch 内始终在 0.849 - 0.867 区间波动，无上升趋势，表明模型在第 13 轮已收敛，所用权重可代表该方法在本数据上的水平。其输入分辨率由模型结构固定为 384，此项与其余组无法对齐。

E4 的等效批量为 4，与其余组不一致，非严格单变量对照。

捷径的表面触发特征仍不清楚。 现象成立（4.2），标注粒度对捷径强度的因果作用成立（4.4），但模型实际依据什么图像特征，4.3 检验的假设已被否定，尚无答案。且粒度只解释了大约一半，缩框后仍余 6.16 倍。归属的决定因素亦未确定，见下条。

该格局在公开数据集中有多普遍，本文未能回答。 5.2 节以同一口径统计了两个数据集的标注粒度，其中只有一个呈现类别间的不一致格局 ($R = 15.2\times$)，另一个为一致的粗标注 ($R = 2.6\times$)。两个样本不足以支持任何关于普遍性的判断，要回答该问题需对公开检测数据集作更大规模的普查。此外，第 4 节的因果链在一个数据集上建立，其向其他数据集的迁移亦未经检验——特别是在不存在孤立最粗类别的数据上，该机制是否仍然成立，尚无证据。

健康负样本的缺失未被单独测定。 主数据集几乎不含无病征图像，该因素足以解释跨物种阴性对照中假阳性的总体水平，但不能解释其类别分布，且在三组反事实中保持恒定（4.2 节）。本文的因果论断因而不受其影响，但“补入健康负样本可在多大程度上降低假阳性总量”这一问题，本文未能回答。

自采数据集尚未标注完成，域偏移的量化评估有待补充。

切图推理一组实验（E7）的设计无效。 我们曾以 SAHI^[12] 切图推理检验小目标假设，结果全线下降，mAP50-95 由 0.516 降至 0.292。事后分析表明该设计不成立：原图尺寸 640

与模型输入相同，切片后再放大属纯上采样，不产生新信息，且引入了训练时未出现过的尺度。该组结果不支持任何结论，此处如实报告，以说明本文的判据在实际执行中确实被应用。

田块尺度的空间格局分析未接入真实数据。 Clark-Evans 最近邻指数、Ripley's L 函数、Moran's I 与 Getis-Ord Gi* 已完成实现，并在合成数据上验证了四种格局可以区分，但自采数据为手持拍摄、不含地理坐标，故本文不作为结果报告，留待获得带坐标的巡检数据后另行开展。

6 结论

本文的统领性问题是：公开数据集的哪些固有属性决定了在其上训练的检测系统是否真正可用。以下五条结论分别回答该问题的一个侧面，其共同指向是——在本文的数据条件下，决定系统可用性的是数据的属性而非模型的选择。

模型侧的优化空间已经耗尽。 参数量 12.4 倍、像素面积 6.25 倍以及一次检测范式更换，统一口径下测试集 mAP50 极差仅 1.54 个百分点。继续在模型侧投入，边际收益极低。

瓶颈在小目标，五个架构一致。 大 / 小目标 AP 之比稳定在 3.10 至 3.81 倍。提高输入分辨率使 AP_small 提升 1.35 个百分点（相对 +8.1%， $p = 0.018$ ）、AP_medium 提升 5.22 个百分点（相对 +14.3%，未达显著），但该改善被聚合指标掩盖——仅依据 mAP50-95 会得出相反的结论。

粗标注的危害不止于单一类别。 三组反事实的比较显示，缩小任一粗标注类别的标注框，不仅使该类自身的分布外假阳性大幅下降（-66% 与 -84%），还使假阳性总量随之降低（9176 $\rightarrow$ 5971 $\rightarrow$ 3956）。这表明标注粒度过粗不只是抬高了某一类的假阳性，还整体提高了模型在陌生输入上产生输出的倾向。标注规范的统一因而具有超出单个类别的价值。

该公开数据集内部的标注粒度不一致，诱导了可量化的捷径学习。 在 5156 张跨物种阴性图像上产生 13.41 倍的过表达假阳性，且置信度高、调节阈值无效、在分布内评估中不可见。反事实重训确立了粒度对该捷径**强度**的因果作用：仅缩小该类的标注框，其分布内 AP 由 0.7609 降至 0.4552，跨物种假阳性减少 66%；整体剔除该类则使假阳性转移至标注次粗的类别。

但标注粒度不决定捷径的归属。 一组事先注册判据的反向操纵给出阴性结果：把标注最细的一类（中位面积 0.57%）粗化至整叶级（40.37%），使其在标注框数与类别占比上均与前述类别相当、分布内性能犹有过之（AP50-95 0.8547 对 0.7338），该类在 5156 张跨物种图像上的假阳性为 0 个框（阈值降至 0.001 时最高置信度仅 0.009，而其分布内 mAP50 为 0.990，为六类中最高），未被操纵的原类别仍占假阳性的 50.0%。故本文的主张为：**标注粒度是该捷径的调制量，而非其成因**——它可放大或削弱一个已经存在的归属地，却不足以造就一个。决定归属的属性本文未能确定；4.3 节的绿色区域假设已被否定，该问题在本文结束时仍然开放（5.3 节）。

毫米级病斑的航拍检测在可行的飞行高度上光学不可达。 无人机的角色应当是冠层级的异常定位，病斑级确诊须由地面环节承担。

后续工作（以下按依赖关系排列，非按重要性）

其一，建立标注粒度统一的自采数据集。 这是其余各项工作的前提，也直接回应第 4 节的发现。要点有二：全部类别采用同一粒度（病斑级）；并纳入足量的健康样本。后者同时提供一项本文未能完成的对照——在标注粒度不变的条件下补入健康负样本，可测定其对假阳性总量的独立贡献，从而将 4.2 节中已作定性辨析的两项因素在数量上分离。

其二，确定捷径归属的决定因素。 这是本文留下的主要问题。4.3 节的绿色区域假设已被否定，4.4 节的反向操纵组进一步排除了标注粒度，缩框后仍余的 6.16 倍过表达亦无解释。首选的候选假设是域相似性——归属地由各类训练图像与分布外输入在整体外观上的接近程度决定（5.3 节）。其检验方式为：度量各类训练图像与 FieldPlant 图像的分布距离，考察该距离能否预测各类的假阳性承接量；并辅以特征归因或输入消融，判别所依据的是纹理、色彩统计还是其他通道。

其三，量化少样本迁移的标注成本。 在上述数据集之上，测定新增一个病害类别或更换作物时所需的最少标注量。该数值决定本方案能否推广——若新增一类需上千个标注框，实际部署中难以承受。

其四，按 5.1 节的光学约束开展冠层级航拍验证。 5.1 节仅给出必要条件（目标尺寸须超过给定像素数），实际检测精度必须以真实航拍数据测定。需注意该任务与本文的病斑级检测并非同一任务，需另行建立数据与标注规范。

其五，病害发展的时序观测。 该项依赖固定机位：若每次拍摄的视角、距离、光照不一致，不同时间点的结果不可比，时序分析将失去意义。因此宜在其一、其四具备条件之后开展，并预先固定观测点位。

参考文献

著录信息（作者、题名、刊名、卷期、页码、DOI）已于 2026-08-13 经 Crossref 与 arXiv 官方接口逐条核对。格式按 GB/T 7714。[6][7][9] 三条截至核对之日仍为 arXiv 预印本，未见正式发表记录。

[1] Geirhos R, Jacobsen J H, Michaelis C, et al. Shortcut learning in deep neural networks[J]. Nature Machine Intelligence, 2020, 2(11): 665-673. DOI: 10.1038/s42256-020-00257-z

[2] Zech J R, Badgeley M A, Liu M, et al. Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs: A cross-sectional study[J]. PLOS Medicine, 2018, 15(11): e1002683. DOI: 10.1371/journal.pmed.1002683

[3] Beery S, Van Horn G, Perona P. Recognition in Terra Incognita[C]//European Conference on Computer Vision (ECCV). Lecture Notes in Computer Science, 2018: 472-489. DOI: 10.1007/978-3-030-01270-0_28

- [4] Lapuschkin S, Wäldchen S, Binder A, et al. Unmasking Clever Hans predictors and assessing what machines really learn[J]. Nature Communications, 2019, 10(1): 1096. DOI: 10.1038/s41467-019-08987-4
- [5] Northcutt C G, Athalye A, Mueller J. Pervasive label errors in test sets destabilize machine learning benchmarks[C]//35th Conference on Neural Information Processing Systems (NeurIPS 2021), Track on Datasets and Benchmarks. 2021. arXiv:2103.14749
- [6] Beyer L, Hénaff O J, Kolesnikov A, et al. Are we done with ImageNet?[EB/OL]. arXiv:2006.07159, 2020-06-12.
- [7] Hughes D P, Salathé M. An open access repository of images on plant health to enable the development of mobile disease diagnostics[EB/OL]. arXiv:1511.08060, 2015-11-25. (PlantVillage 数据集)
- [8] Mohanty S P, Hughes D P, Salathé M. Using deep learning for image-based plant disease detection[J]. Frontiers in Plant Science, 2016, 7: 1419. DOI: 10.3389/fpls.2016.01419
- [9] Noyan M A. Uncovering bias in the PlantVillage dataset[EB/OL]. arXiv:2206.04374, 2022-06-09.
- [10] Moupojou E, Tagne A, Retraint F, et al. FieldPlant: A dataset of field plant images for plant disease detection and classification with deep learning[J]. IEEE Access, 2023, 11: 35398-35410. DOI: 10.1109/ACCESS.2023.3263042
- [11] Nikouei M, Baroutian B, Nabavi S, et al. Small object detection: A comprehensive survey on challenges, techniques and real-world applications[J]. Intelligent Systems with Applications, 2025, 27: 200561. DOI: 10.1016/j.iswa.2025.200561
- [12] Akyon F C, Altinuc S O, Temizel A. Slicing aided hyper inference and fine-tuning for small object detection[C]//IEEE International Conference on Image Processing (ICIP). 2022: 966-970. DOI: 10.1109/ICIP46576.2022.9897990 (SAHI)
- [13] Bolya D, Foley S, Hays J, et al. TIDE: A general toolbox for identifying object detection errors[C]//European Conference on Computer Vision (ECCV). Lecture Notes in Computer Science, 2020: 558-573. DOI: 10.1007/978-3-030-58580-8_33
- [14] Lin T Y, Maire M, Belongie S, et al. Microsoft COCO: Common objects in context[C]// European Conference on Computer Vision (ECCV). Lecture Notes in Computer Science, 2014: 740-755. DOI: 10.1007/978-3-319-10602-1_48 (分尺度分档定义与 pycocotools 评估实现的出处)

[15] Ultralytics. YOLO11: Version 8.4.106 [CP/OL]. (2026-08-13) [2026-08-13]. <https://github.com/ultralytics/ultralytics>

[16] Roboflow. RF-DETR: Version 1.8.3 [CP/OL]. (2026-08-13) [2026-08-13]. <https://github.com/roboflow/rf-detr>

[17] Zhao Y, Lv W, Xu S, et al. DETRs beat YOLOs on real-time object detection[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024: 16965–16974. DOI: 10.1109/CVPR52733.2024.01605 (RT-DETR)

附录 可复现性

全部实验固定随机种子，相同软硬件下可复现。环境为 Windows、RTX 4060 Laptop 8 GB、PyTorch 2.13.0+cu132、Python 3.11。最大显存占用 2.8 GB（YOLO11s，批量 8，分辨率 640），远低于 8 GB 上限——本方案的训练与部署不依赖高性能计算设备。

全部分布内指标由 pycocotools 在同一测试集、同一置信度阈值下计算，包括第 4 节的反事实各组；逐类别与分尺度指标均已落盘，可完整复核。

脚本	用途	产物
<code>scripts/Eval_unified.py</code>	五组模型统一 pycocotools 口径评估	<code>results/runs_unified/table3_unified.json</code>
<code>scripts/Eval_perclass_seeds.py</code>	逐类别 AP 的种子间波动（表 10 末列）	<code>results/runs_unified/perclass_seed_variance.json</code>
<code>scripts/Shortcut_experiment.py</code>	跨物种阴性对照	<code>results/runs_shortcut/shortcut_*.json</code>
<code>scripts/Counterfactual_prepare.py</code>	反事实数据集构造	<code>datasets/grape_cf_*</code>
<code>scripts/Counterfactual_train.py</code>	反事实重训	<code>runs/detect/E10*、E12_placebo、E13_expand</code>
<code>scripts/Eval_counterfactual.py</code>	反事实组分布内评估（表 10、表 14）	<code>results/runs_unified/counterfactual_unified*.json</code>
<code>scripts/Conf_sweep.py</code>	低阈值复测：区分硬零与阈值效应（结果五）	控制台输出，见 4.4 节
<code>scripts/Granularity_stats.py</code>	跨数据集的标注粒度统计（表 17）	<code>results/runs_unified/granularity_stats.json</code>
<code>scripts/Gsd_planner.py</code>	采集参数与可行性核算	表 15、表 16

反事实数据集仅有 YOLO 格式标注，`scripts/Eval_counterfactual.py` 由其构造 COCO 标注时，图像 id、file_name 与类别 id 全部沿用原测试集，仅替换标注框。该转换的正确性可由一项自检确认：未被操纵的五个类别，在新旧两份标注上给出逐位相同的 AP。

4.4 节结果五的判据为事先注册：三档阈值、主指标的选择及其理由，连同该数据集筛查量的预测，均写入 `scripts/Shortcut_experiment.py` 的文件头，其写入时间早于该组训练完成。判定由代码按 3×3 决策表自动给出，九种组合均有预先指定的读法，不存在留待事后解释的空档；判定结果与筛查量随假阳性数字一并落盘于 `results/runs_shortcut/shortcut_E13.json` 的 `prereg_verdict` 与 `screening` 字段。将

E1 的基线数值代入该表，判定为“证伪”——即“未发生变化”必然落在证伪一侧， 该表不偏向确认。

开源资源与许可

资源	许可	用途
葡萄病害检测数据集 (wscs/grape-uyimv v1)	CC BY 4.0	主实验
FieldPlant (plant-disease-detection/fieldplant v11)	CC BY 4.0	流程验证、跨物种阴性对照
Ultralytics YOLO11	AGPL-3.0	E1 - E4
RF-DETR	Apache 2.0	E5
pycocotools	BSD	指标计算
SAHI	MIT	E7
X-AnyLabeling	GPL-3.0	自采数据标注

Ultralytics 采用 AGPL-3.0，对衍生作品的分发有开源要求；RF-DETR 为 Apache 2.0，商用约束较少。该差异已在后续技术选型中纳入考量。

生成式人工智能使用声明

在本文撰写过程中，作者使用了生成式人工智能工具，用于文献综述部分的行文组织、背景材料的文字整理、语言润色、表格与格式编排，以及实验数据的核对与统计计算的脚本编写。

全部研究工作由作者独立完成，包括：研究问题的提出、实验设计与对照设置、数据采集与处理、模型训练与评估、结果解释与结论提炼。文中所有实验均在作者的设备上执行，原始数据、模型权重与中间结果均予保存并可复核。

作者已对全文内容逐句核查，并对论文的科学性与准确性负全部责任。生成式人工智能未被列为作者，亦未参与研究构思、假设提出与结论判断。

投稿前请核对目标期刊对该声明的具体格式与放置位置要求； 多数期刊的在线投稿系统另设单独的 AI 使用勾选项，需一并填写。